Arquitecturas ETL y Modelos de IA Aplicados

INSTITUCIÓN UNIVERSITARIA

SNIES 4709

Especialización en Analítica de Datos Aplicada a los Negocios

¿Quién soy?

- Robert García Rey
- Científico de Datos en Bancolombia - Tuya S.A
- Ingeniero de Petróleos | Especialista en Analítica de Datos | Maestría en Ingeniería de Software e Inteligencia Artificial (en curso)
- Experiencia en análisis de grandes volúmenes de datos, desarrollo y despliegue de modelos de machine learning.
- Correo: garcia.robert.0514@eam.edu.co

Fundamentos, Arquitectura y Gobernanza

SESIÓN 1

Fundamentos y Arquitectura

- Roles en el ecosistema de datos (Skills y Recomendaciones).
- Databricks Fundamentales (Spark, Delta Lake, UC).
- Modelos: Warehouse vs. Lake vs. Lakehouse.
- Arquitectura de Objetos y Gestión de Clusters.

SESIÓN 2

Gobernanza y Unity Catalog

- Definición y Espectro de Gobernanza.
- Unity Catalog (UC) desde la perspectiva de gestión.

Ingeniería, Operaciones y Rendimiento

SESIÓN 3

Ingeniería de Datos y Operaciones

- Pipelines ETL con Delta Lake
- Manejo de permisos en producción y herramientas de orquestación avanzada.

SESIÓN 4

Optimización y Rendimiento

- Fundamentos y diagnóstico de rendimiento
- Técnicas de optimización
- Diseño de pipelines escalables y sostenibles

Machine Learning Lifecycle

SESIÓN 5

Machine Learning

- → Databricks para ML.
- → MLflow: Construcción y Tracking de modelos.
- → Deployment: Despliegue y gestión profesional.

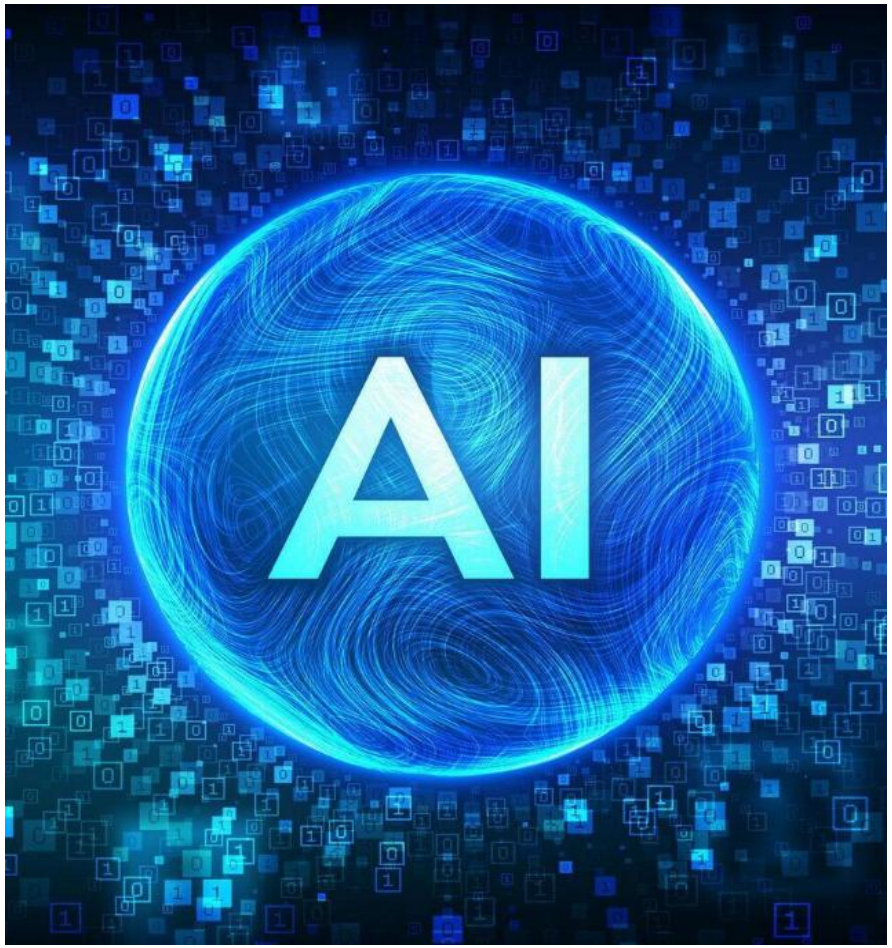

Introducción a la Asignatura | Data roles ecosystem I

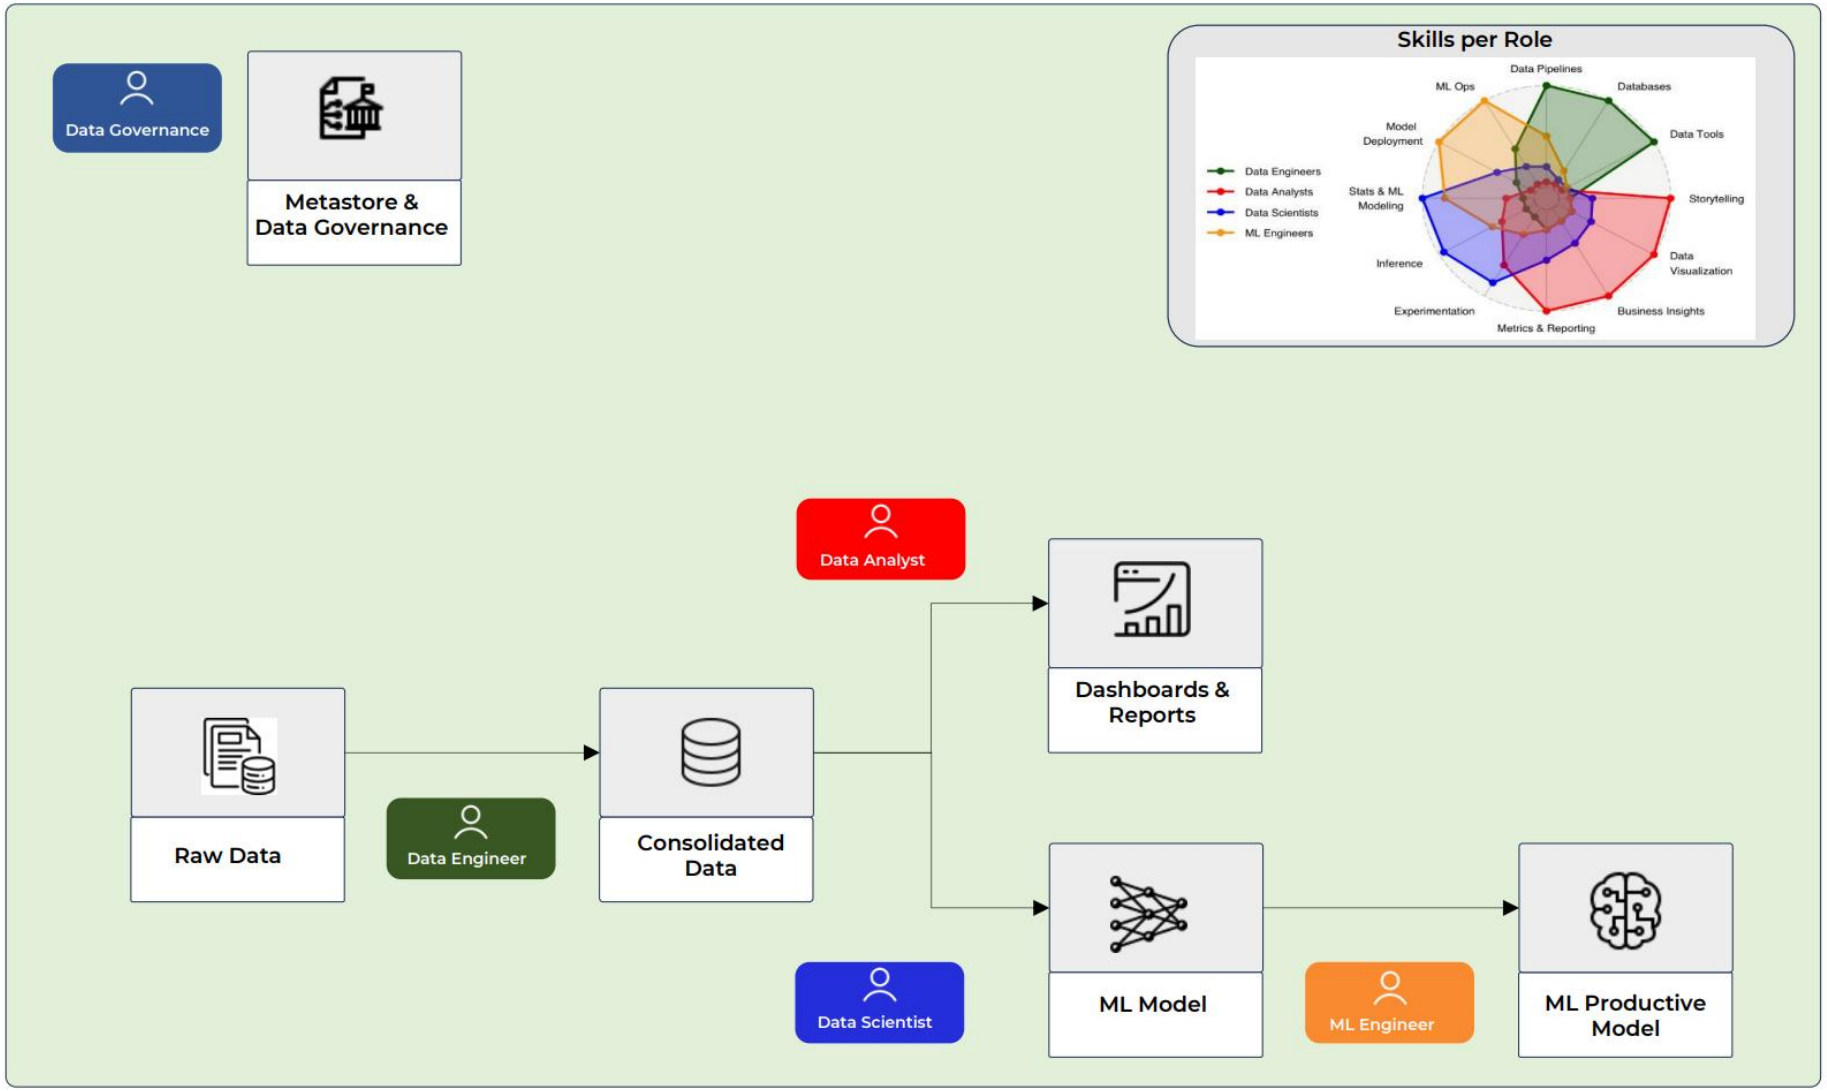

Introducción a la Asignatura | Data roles ecosystem II

Data Analyst

- Business Intelligence Analyst (BI Analyst)
- Reporting Analyst
- Analytics Analyst
- Product Analyst
- Business Analyst (data-focused)

Data Engineer

- Analytics Engineer
- BI Engineer
- Data Platform Engineer
- Cloud Data Engineer
- ETL / ELT Engineer

Data Governance

- Data Governance Specialist
- Data Steward
- Data Management Analyst
- Metadata / Catalog Manager
- Enterprise Data Governance

Data Scientist

- Applied Data Scientist
- Decision Scientist
- Advanced Analytics Scientist
- Quantitative Analyst (Quant)
- Research Data Scientist

ML Engineer

- Machine Learning Engineer
- MLOps Engineer
- Applied Machine Learning Engineer
- AI Engineer
- ML Platform Engineer

DATABRICKS FUNDAMENTALES

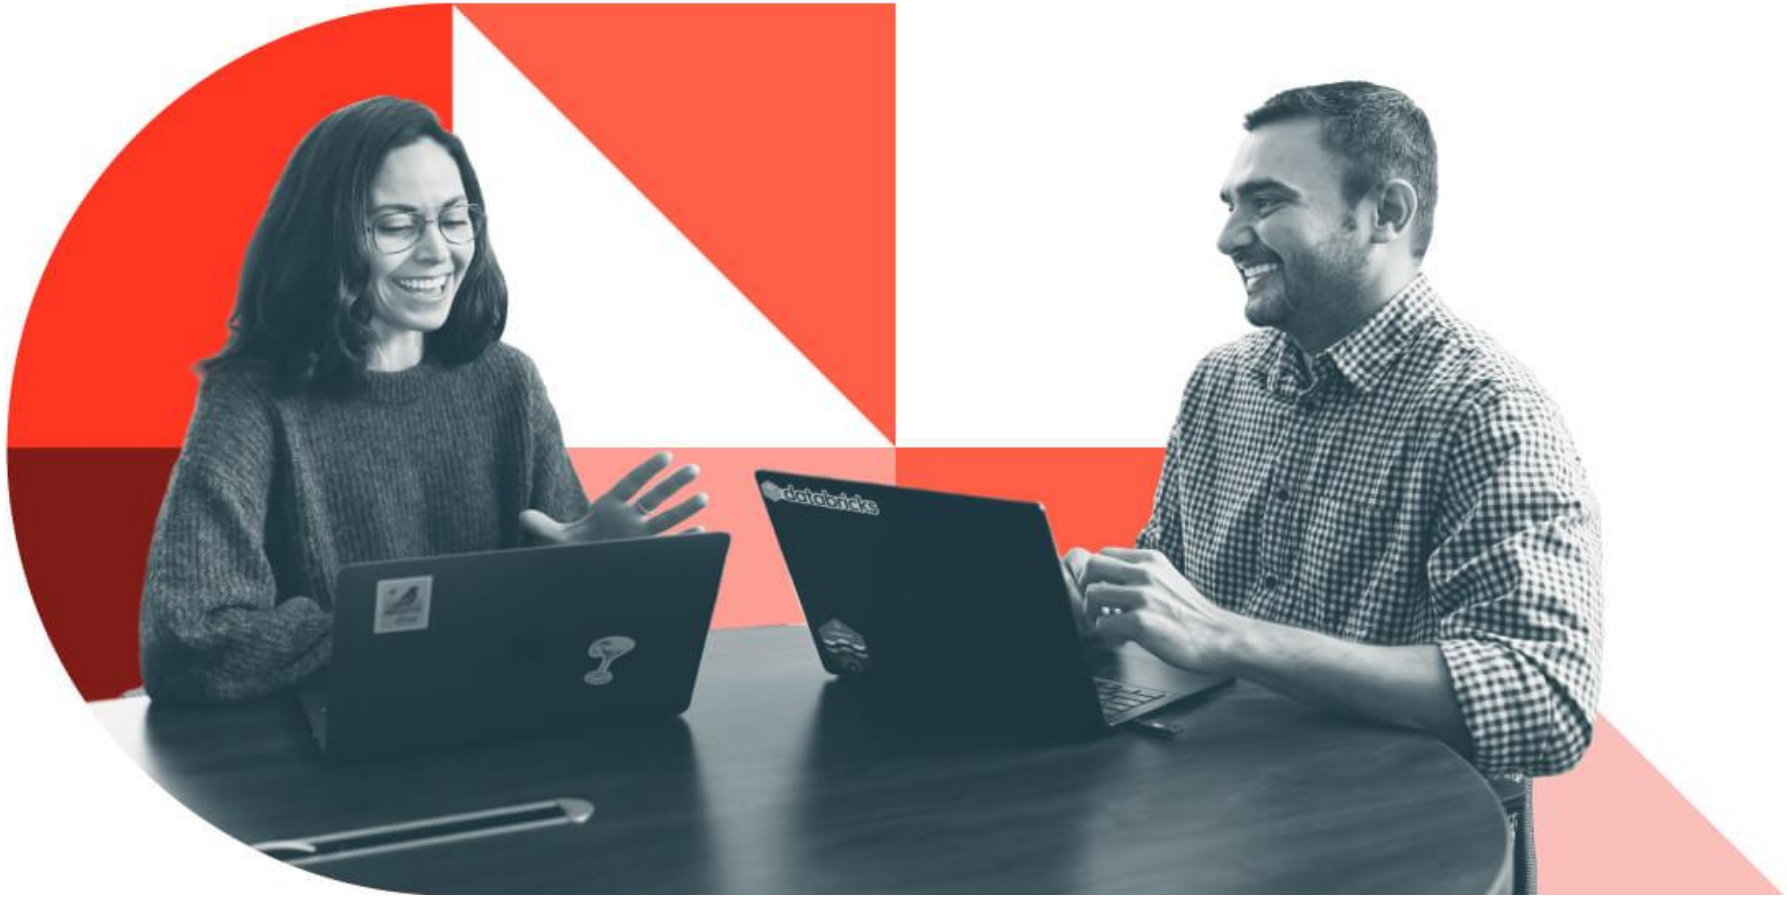

Databricks Fundamentales | Los 3 Pilares

- Motor distribuido de procesamiento que permite **trabajar en paralelo sobre grandes volúmenes de datos**, tanto batch como streaming.
- Organiza el trabajo con **Driver, Workers, Executors y DAGs**,

- Formato de almacenamiento que añade **ACID, versionado, y esquema evolutivo** sobre archivos Parquet.
- Permite **time travel, upserts, merges optimizados y data quality checks**, ideal para pipelines medallion.

- Sistema centralizado para gestionar **seguridad, permisos, catalogación y lineage de datos** entre diferentes Workspaces.
- Permite gobernanza unificada con **control de acceso a nivel de catálogo, esquema, tabla y columna (incluida datos sensibles/PII)**.

Databricks Fundamentales | Data Warehouse

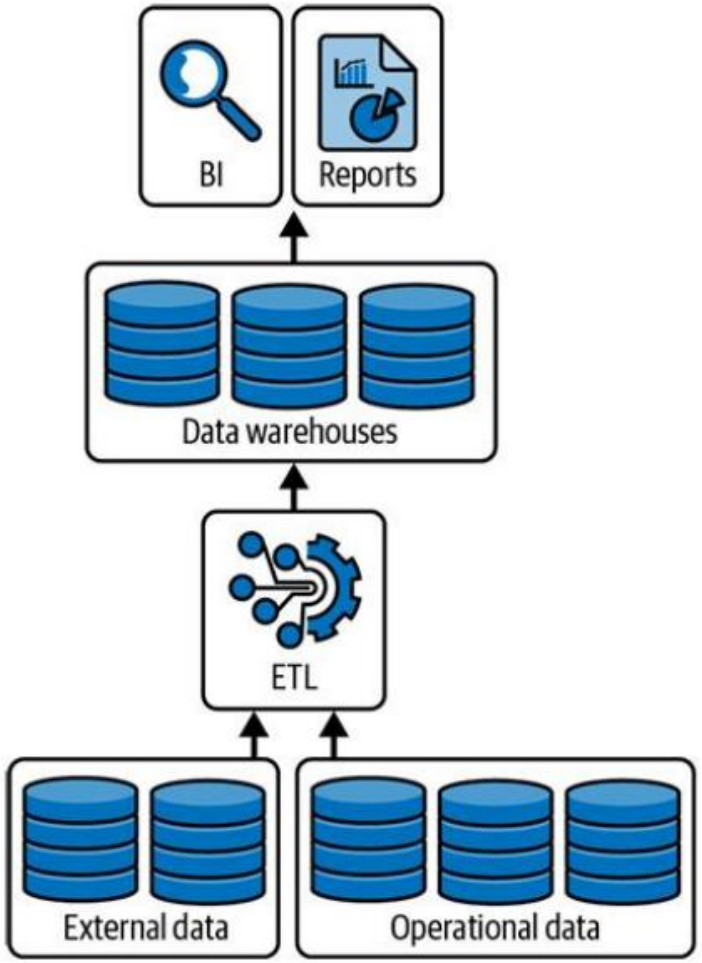

Data Warehouse

✅ Pros:
1. Estructura clara y gobernabilidad
2. Ideal para **BI y SQL tradicional**

❌ Cons:
1. Difícil manejar datos **no estructurados** (audio, video, texto)
2. No está pensado para **Machine Learning** ni **ciencia de datos**
3. Poco flexible ante grandes volúmenes o variedad de datos

Databricks Fundamentales | Data Lake

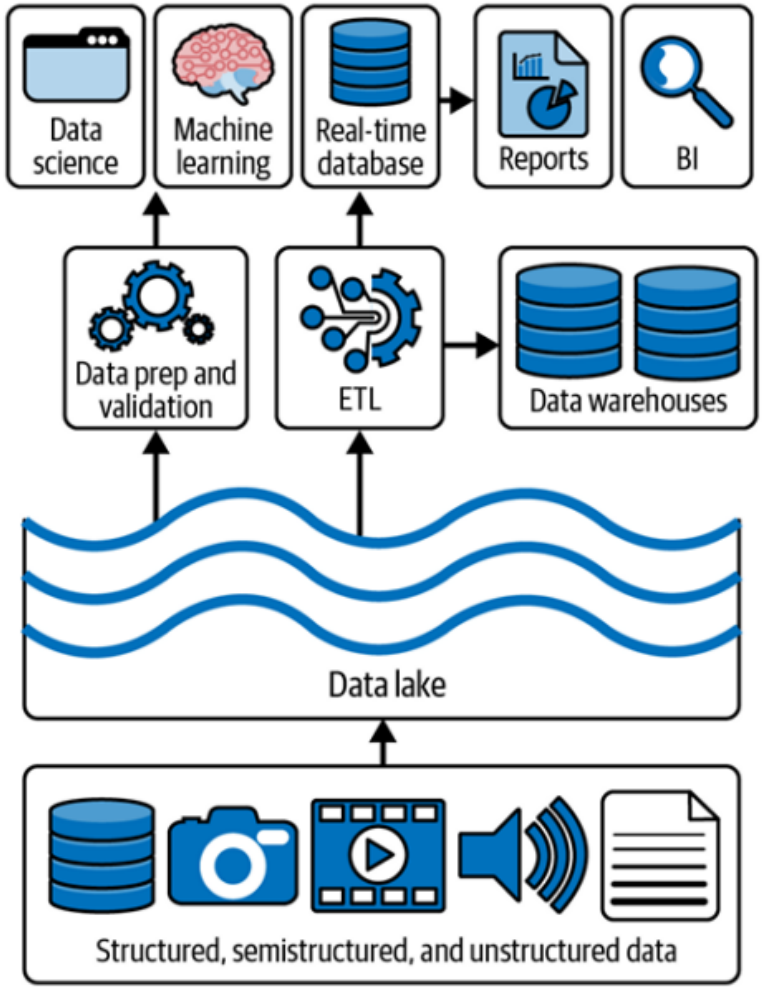

Data Lake

✅ Pros:
1. Escalable y económico (almacenamiento en bruto)
2. Acepta **cualquier tipo de datos** (estructurados o no)

❌ Cons:
1. **Sin control de calidad** → puede volverse una "ciénaga de datos"
2. Bajo rendimiento para consultas
3. Mala integración con herramientas BI
4. No garantiza integridad ni transacciones

Databricks Fundamentales | Data Lakehouse

Data Warehouse

Pros:
1. Estructura clara y gobernabilidad
2. Ideal para **BI y SQL tradicional**

Cons:
1. Difícil manejar datos **no estructurados** (audio, video, texto)
2. No está pensado para **Machine Learning** ni **ciencia de datos**
3. Poco flexible ante grandes volúmenes o variedad de datos

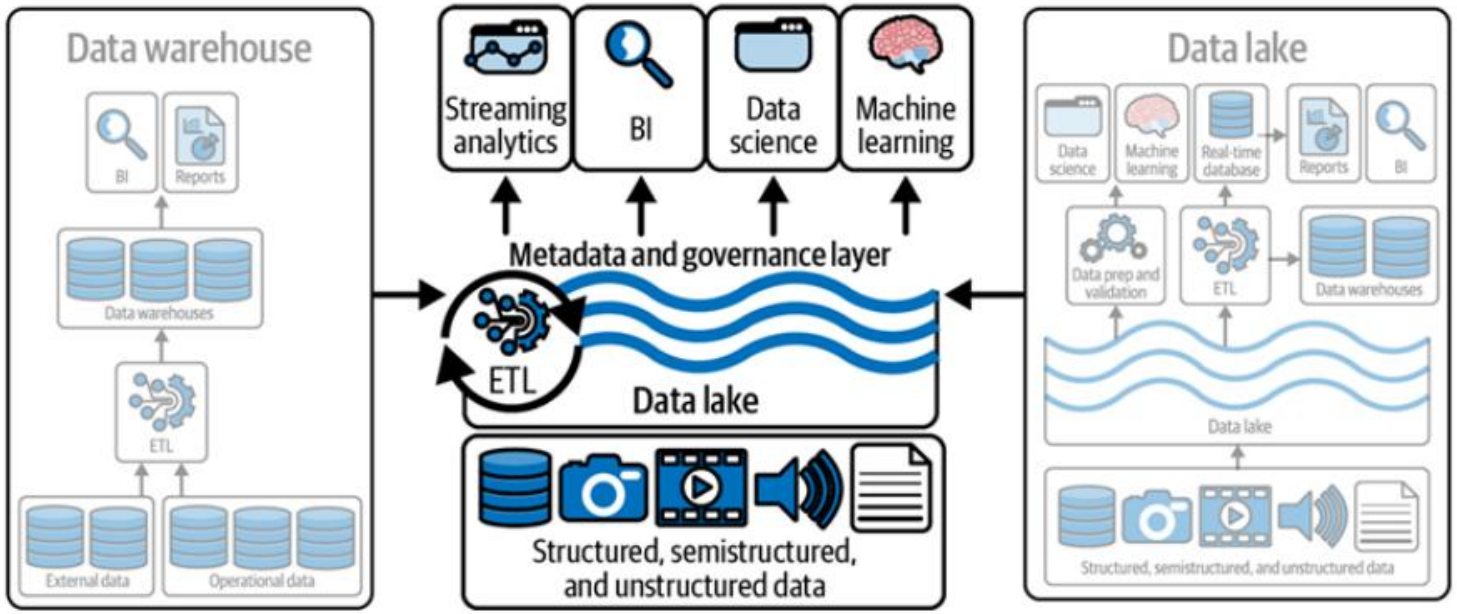

Data Lake

Pros:
1. Escalable y económico (almacenamiento en bruto)
2. Acepta cualquier tipo de datos (estructurados o no)

Cons:
1. Sin control de calidad → puede volverse una "ciénaga de datos"
2. Bajo rendimiento para consultas
3. Mala integración con herramientas BI
4. No garantiza integridad ni transacciones

El **Data Lakehouse** es la **evolución natural** que:

1. Une lo **mejor del Data Warehouse** (gobierno, fiabilidad, rendimiento)
2. Con lo **mejor del Data Lake** (flexibilidad, diversidad, escalabilidad)

Databricks | Ecosistema de Datos I

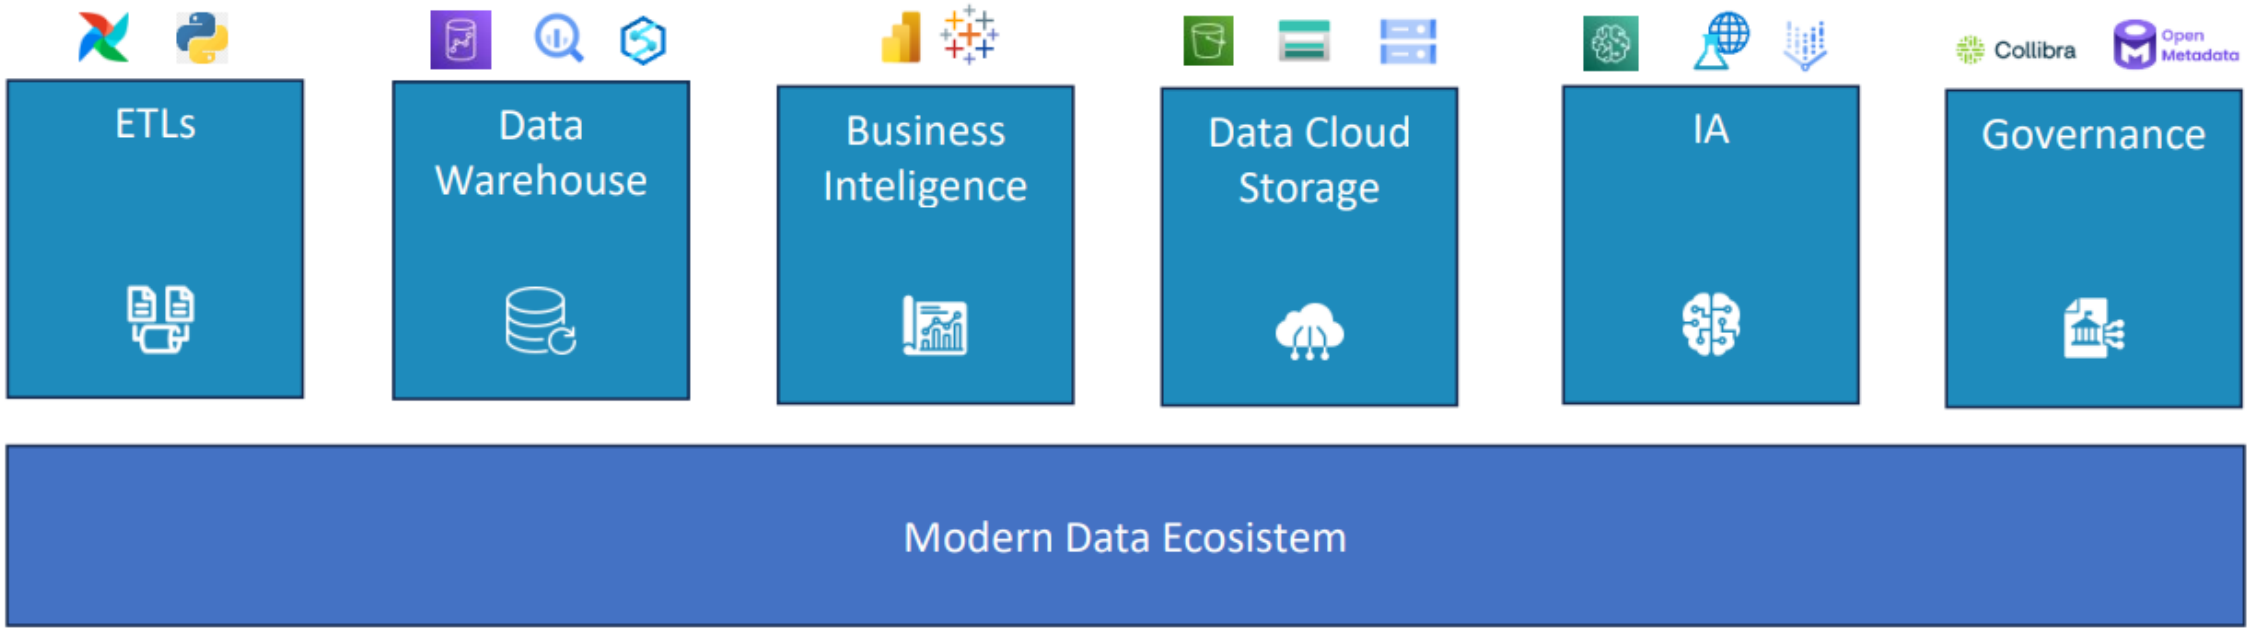

Databricks | Ecosistema de Datos II

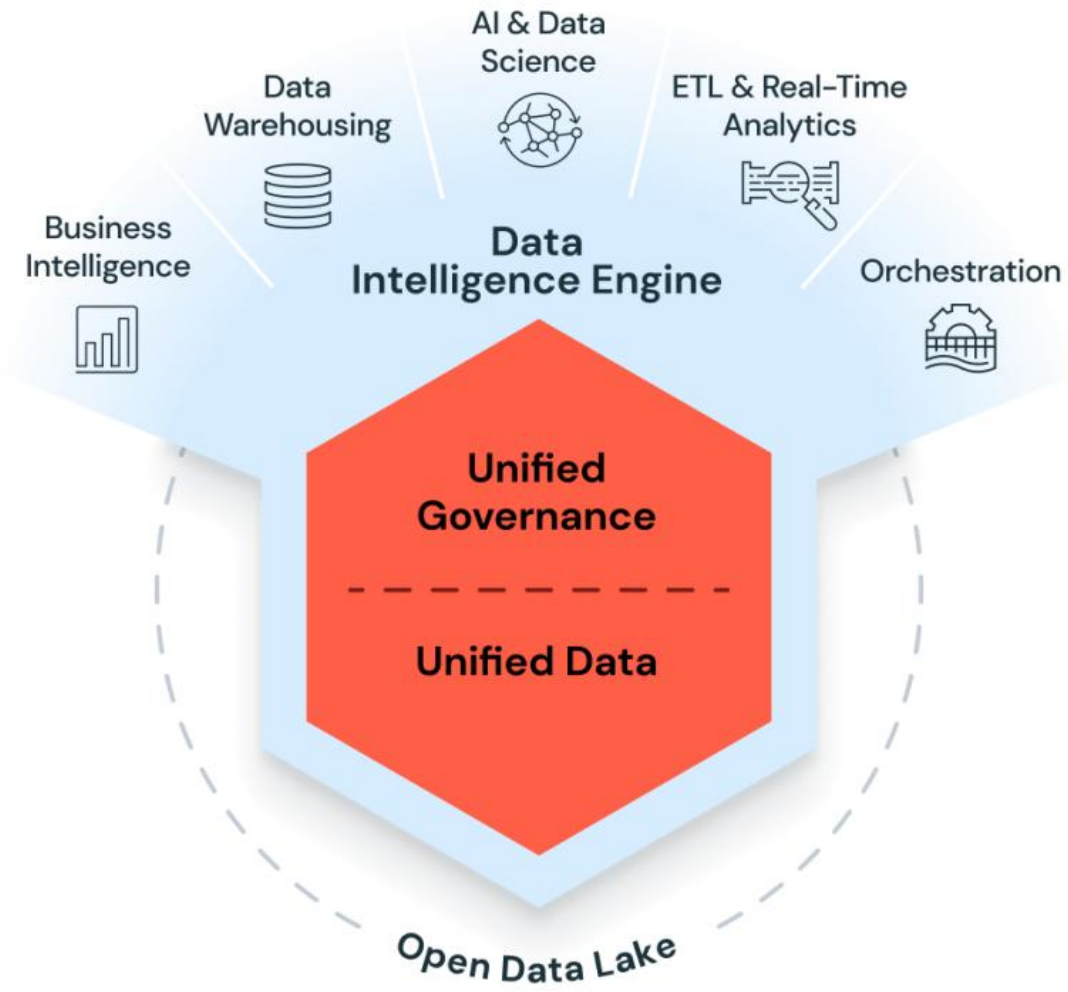

DEMO

APERTURA DE CUENTA EN DATABRICKS
EXPLORACIÓN DEL ENTORNO

Arquitectura UC | Objetos en UC

Nivel 1 — Catálogo (máximo nivel de organización y gobernanza)Agrupa y aísla los recursos de datos a nivel corporativo. Normalmente refleja unidades organizativas, entornos (dev/test/prod) o dominios globales.

Nivel 2 — Esquema (espacio lógico de trabajo por proyecto o equipo) Subdivisión dentro del catálogo para organizar datos por caso de uso, área funcional o equipo de trabajo, aislando su contexto operativo.

Nivel 3 — Objetos (donde realmente residen o se consumen los datos)
Elementos concretos dentro del esquema:
Tablas → datos estructurados gestionados por UC
Vistas → consultas reutilizables y gobernadas
Volúmenes → archivos crudos o semiestructurados en cloud storage
Funciones → lógica reutilizable para transformar o proteger datos

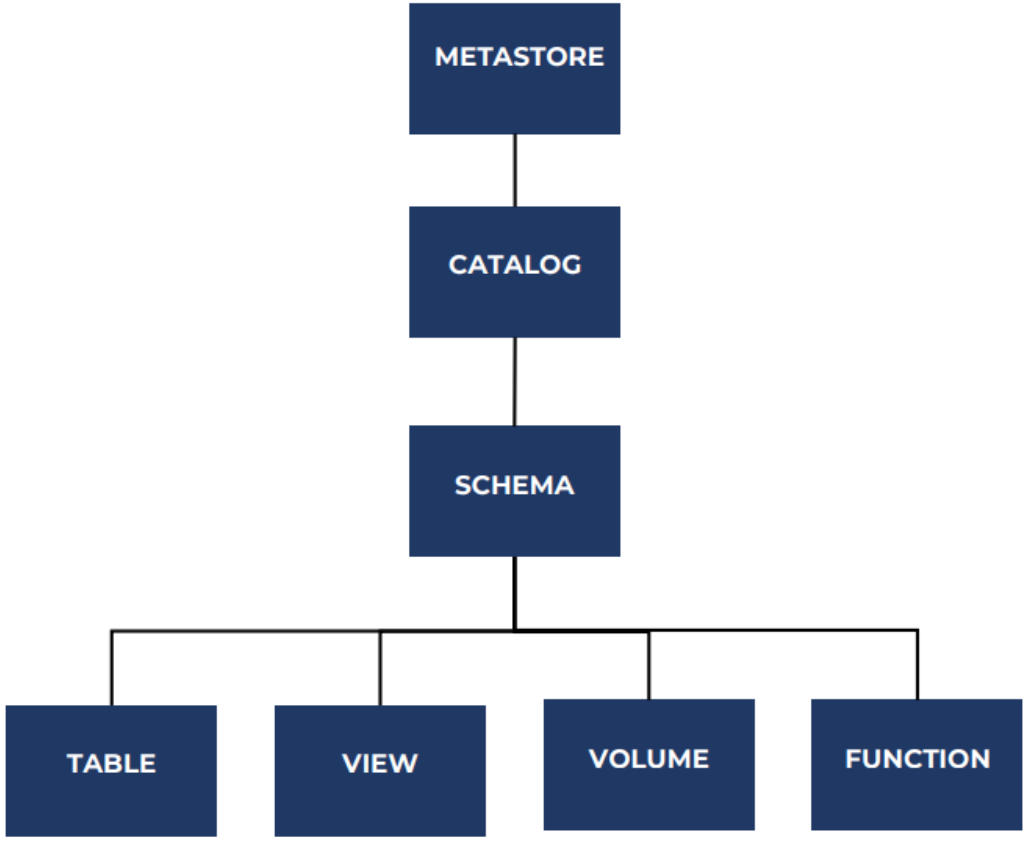

Arquitectura | Nivel Organizativo en Databricks

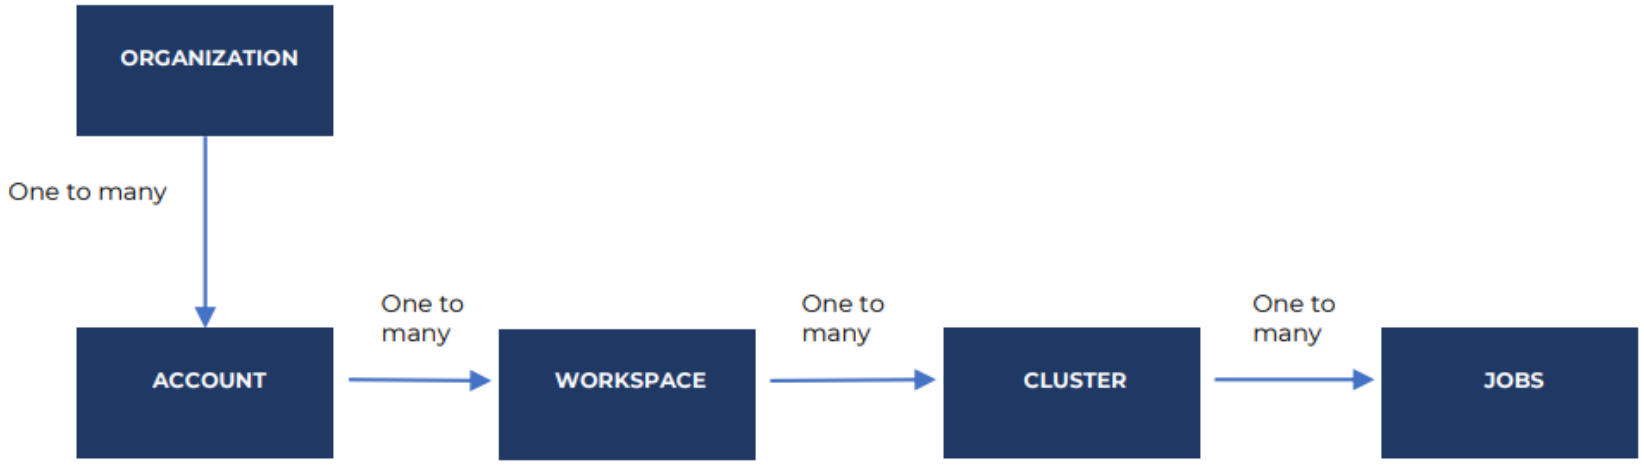

DEMO

CREACIÓN DE OBJETOS EN UC
INTRO A PYSPARK

Tabla Delta | ¿Qué es Delta Lake?

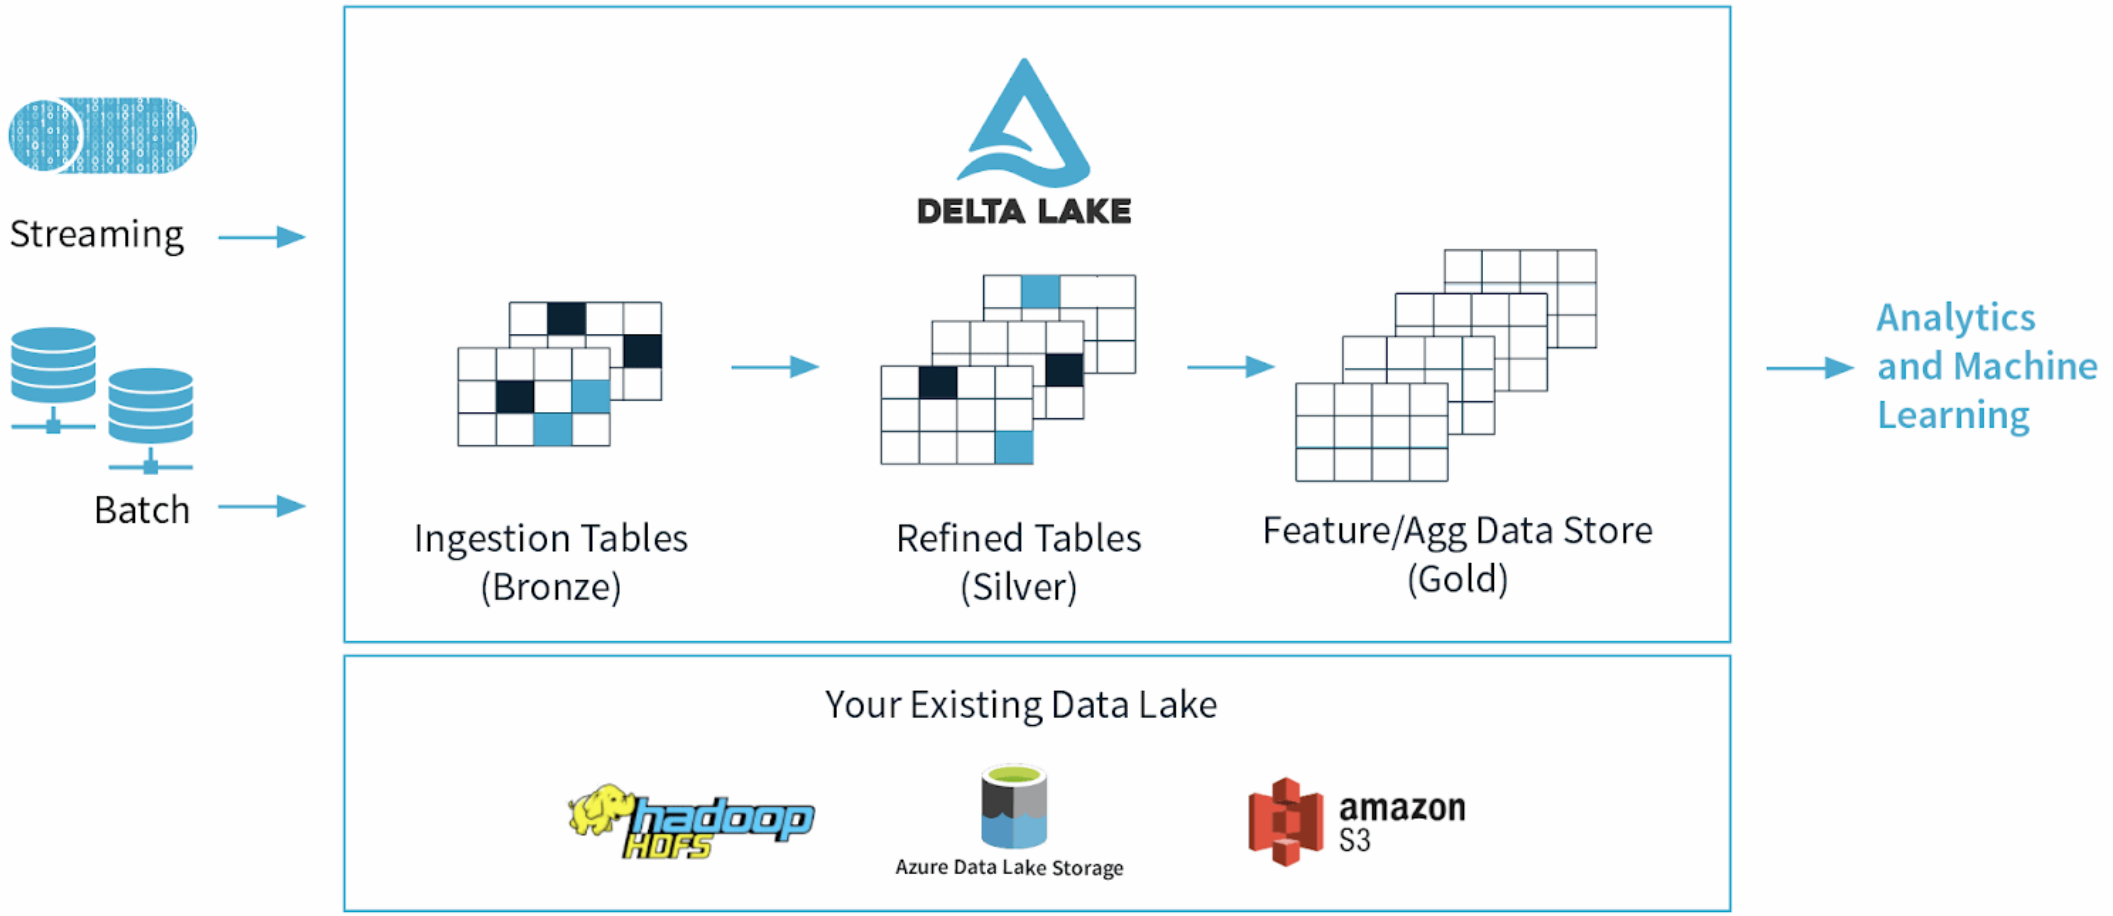

Tabla Delta | ¿Qué es una Tabla Delta?

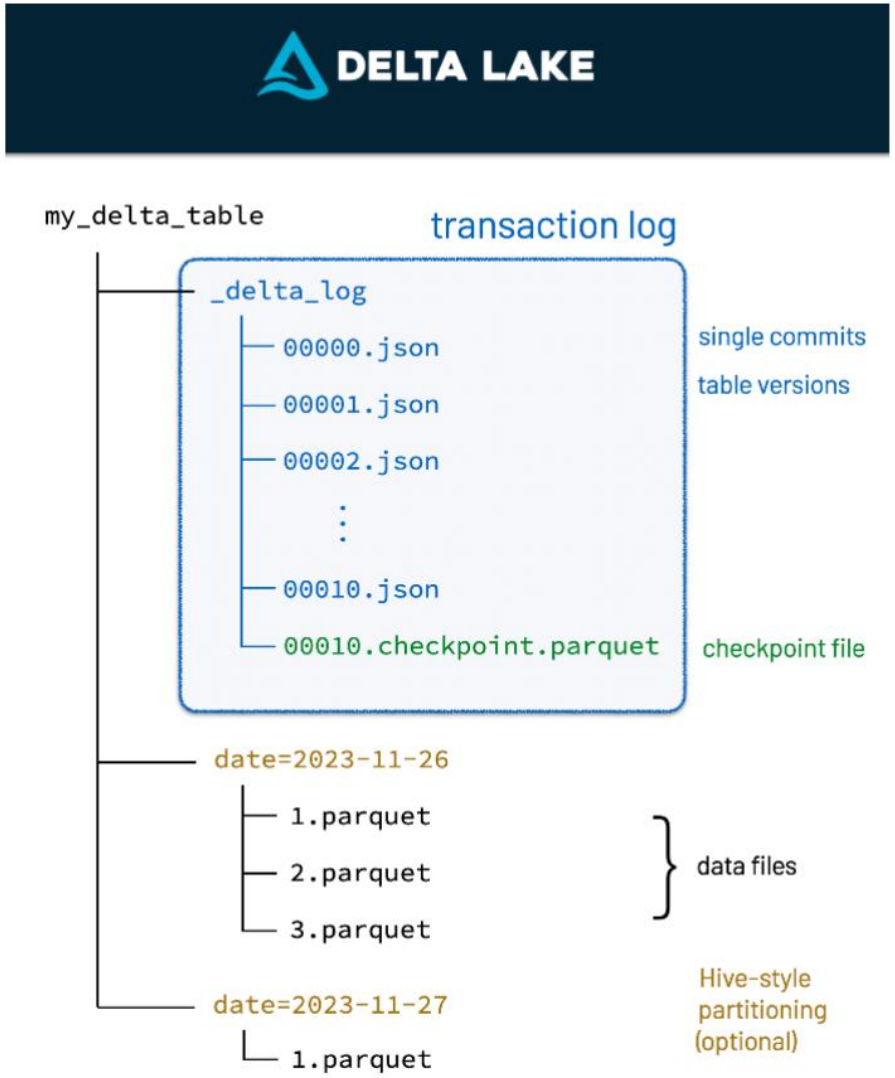

El Modelo de Ejecución de Spark: Evaluación Perezosa (Lazy Evaluation)

Explicar cómo Apache Spark optimiza el procesamiento de datos diferenciando entre la definición de tareas (Transformaciones) y su ejecución real (Acciones).

Transformaciones (Construcción del Plan)

Las Transformaciones son "Lazy"

No ejecutan nada al encadenarse; solo definen un nuevo DataFrame o RDD para el plan.

Transformaciones Estrechas (Narrow)
Las estrechas actúan localmente.

Tipo de	Transformación y Rendimiento	Impacto en Rendimiento
Narrow (Estrechas)	filter, select, map, union	(Ejecución local)
Wide (Anchas)	groupBy, join, distinct	(Requiere Shuffles)

Transformaciones Anchas (Wide)
mientras que las anchas (como **groupBy**) requieren mover datos (**shuffles**). **groupBy, join, distinct**

Ejemplos de Transformaciones
Operaciones comunes incluyen **map, filter, select** (Narrow) y **join** o **repartition** (Wide).

Acciones (El Disparador de Ejecución)

La Acción como Disparador (Trigger)

Una acción hace que Spark "despierte" y ejecute el plan de operaciones acumulado.

Optimización con Catalyst

Al esperar a la acción, Spark optimiza el plan global para minimizar movimientos innecesarios.

Ejemplos de Acciones
Comandos como **count()**, **show()**, **collect()** o **save()** inician la computación real.

RESULTADO

Clusters | ¿Qué es?

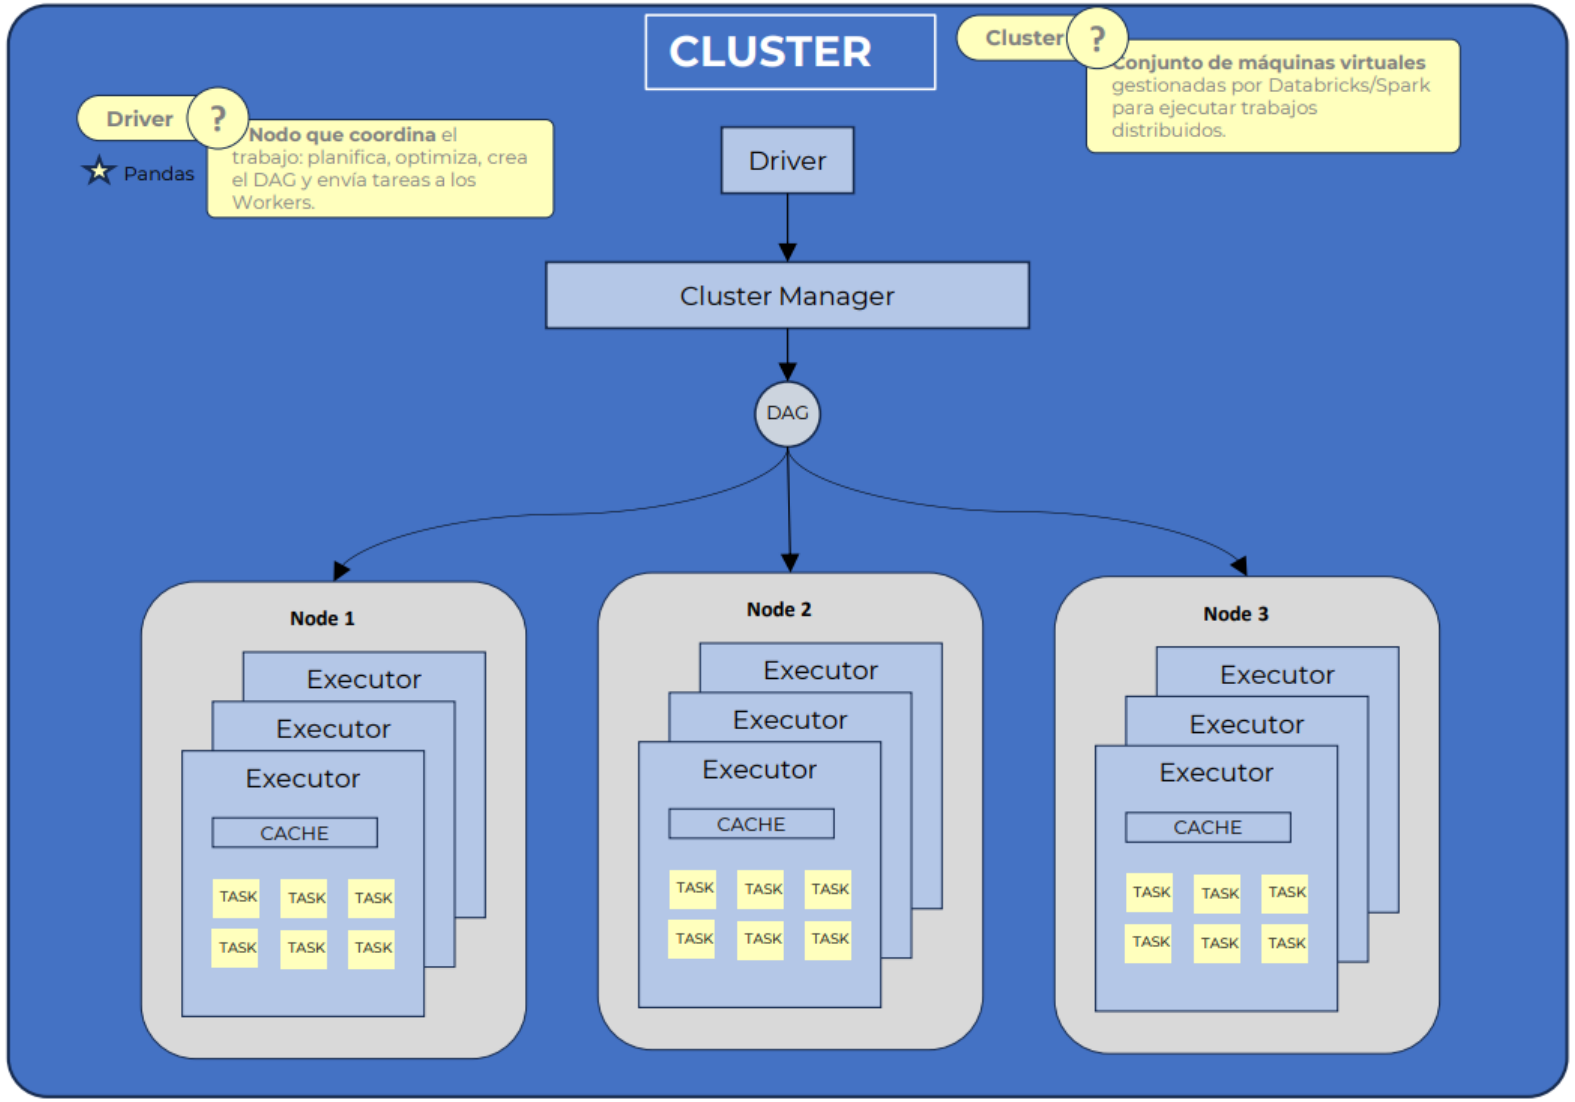

Clusters | Modos de Acceso

Single User Access Mode

- **Solo una identidad** puede usarlo: el propietario.
- Autenticación y permisos controlados al 100% por **Unity Catalog** + IAM.
- Ideal para **seguridad alta**, acceso a datos sensibles, ML, Service Principals.

=> Ejemplo de contexto:
"Estoy desarrollando un modelo de ML con acceso a datos sensibles: cluster Single User."

Shared Access Mode

- **Varias personas** pueden usar el mismo cluster.
- Cada notebook se ejecuta con la **identidad real del usuario**.
- Permite **colaboración** y mantiene permisos individuales.

⇒ Ejemplo de contexto:
"Estamos editando notebooks en equipo y cada uno ve solo lo que tiene permiso—Shared Mode."

No Isolation Shared Access Mode

- Todos los usuarios comparten la **misma identidad** técnica.
- **No hay control de credenciales** individuales.
- **No soporta Unity Catalog** ni passthrough.

=> Ejemplo de contexto:
"Uso un cluster antiguo para pruebas rápidas con datos no sensibles."

Clusters | Tipos de Clusters

All-Purpose Clusters

- ideales para el **desarrollo interactivo**, las pruebas y la colaboración.
- Espacio de trabajo compartido para **crear y experimentar**

JOB Clusters

- diseñados específicamente para ejecutar **tareas programadas** o activadas.
- Se activan para la tarea y **se apagan automáticamente cuando terminan**, lo que los hace ideales para ETL de producción.

Clusters Pools

- una forma de precalentar los recursos informáticos para que los clústeres **se inicien más rápido.**
- Perfectos para entornos con **trabajos cortos frecuentes**.

SQL Warehouses

- optimizados para consultas SQL y herramientas de BI.

DEMO

Exploración de Datos con Spark
DBUtils
Dashboards Intro

2 Introducción a UC | ¿Qué es Gobernanza?

Gobernanza de datos = políticas + procesos + responsabilidades + herramientas para que los datos sean:

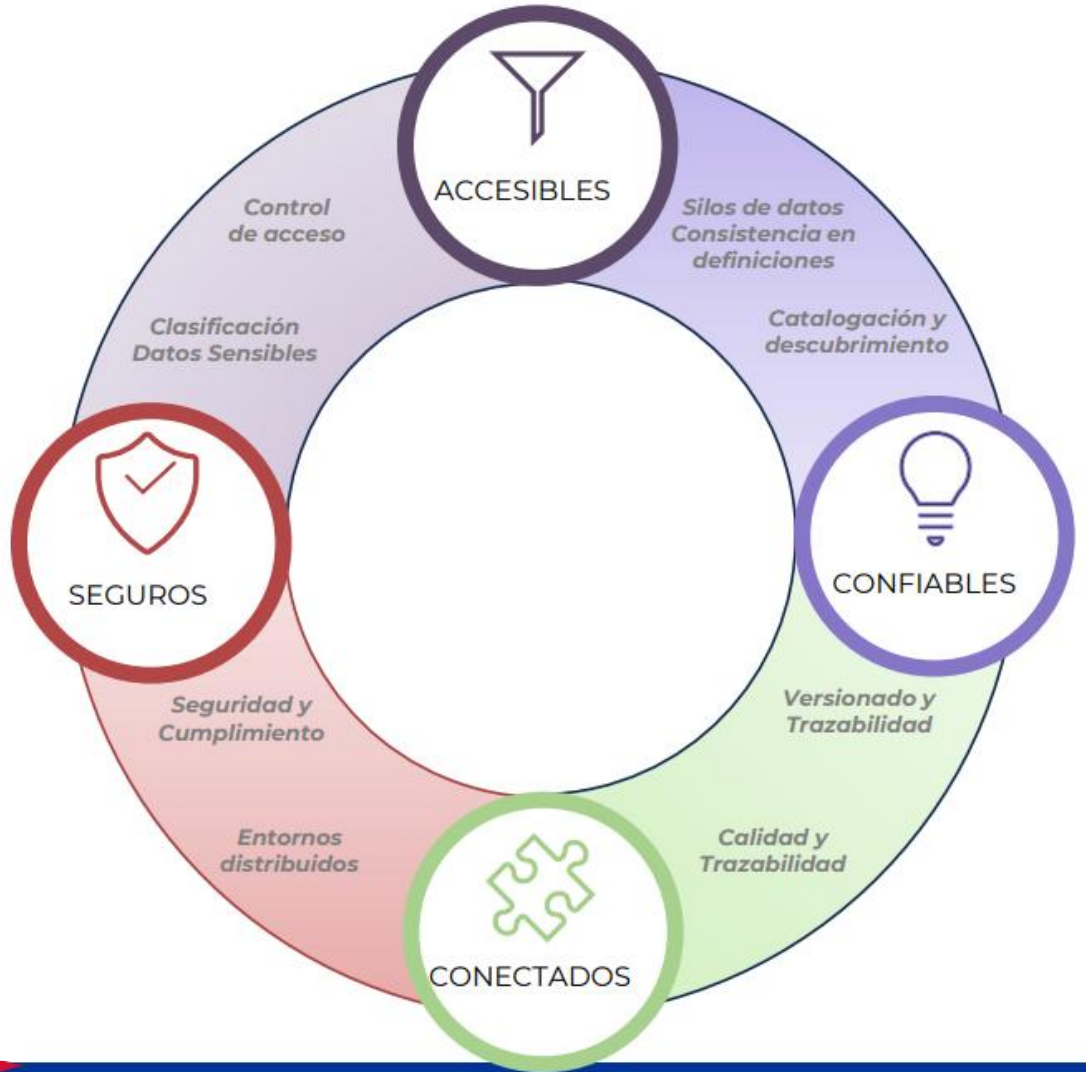

Gobernar datos no es solo protegerlos, es también hacerlos utilizables con confianza.

2 Introducción a UC | Espectro de Gobernanza en las empresas

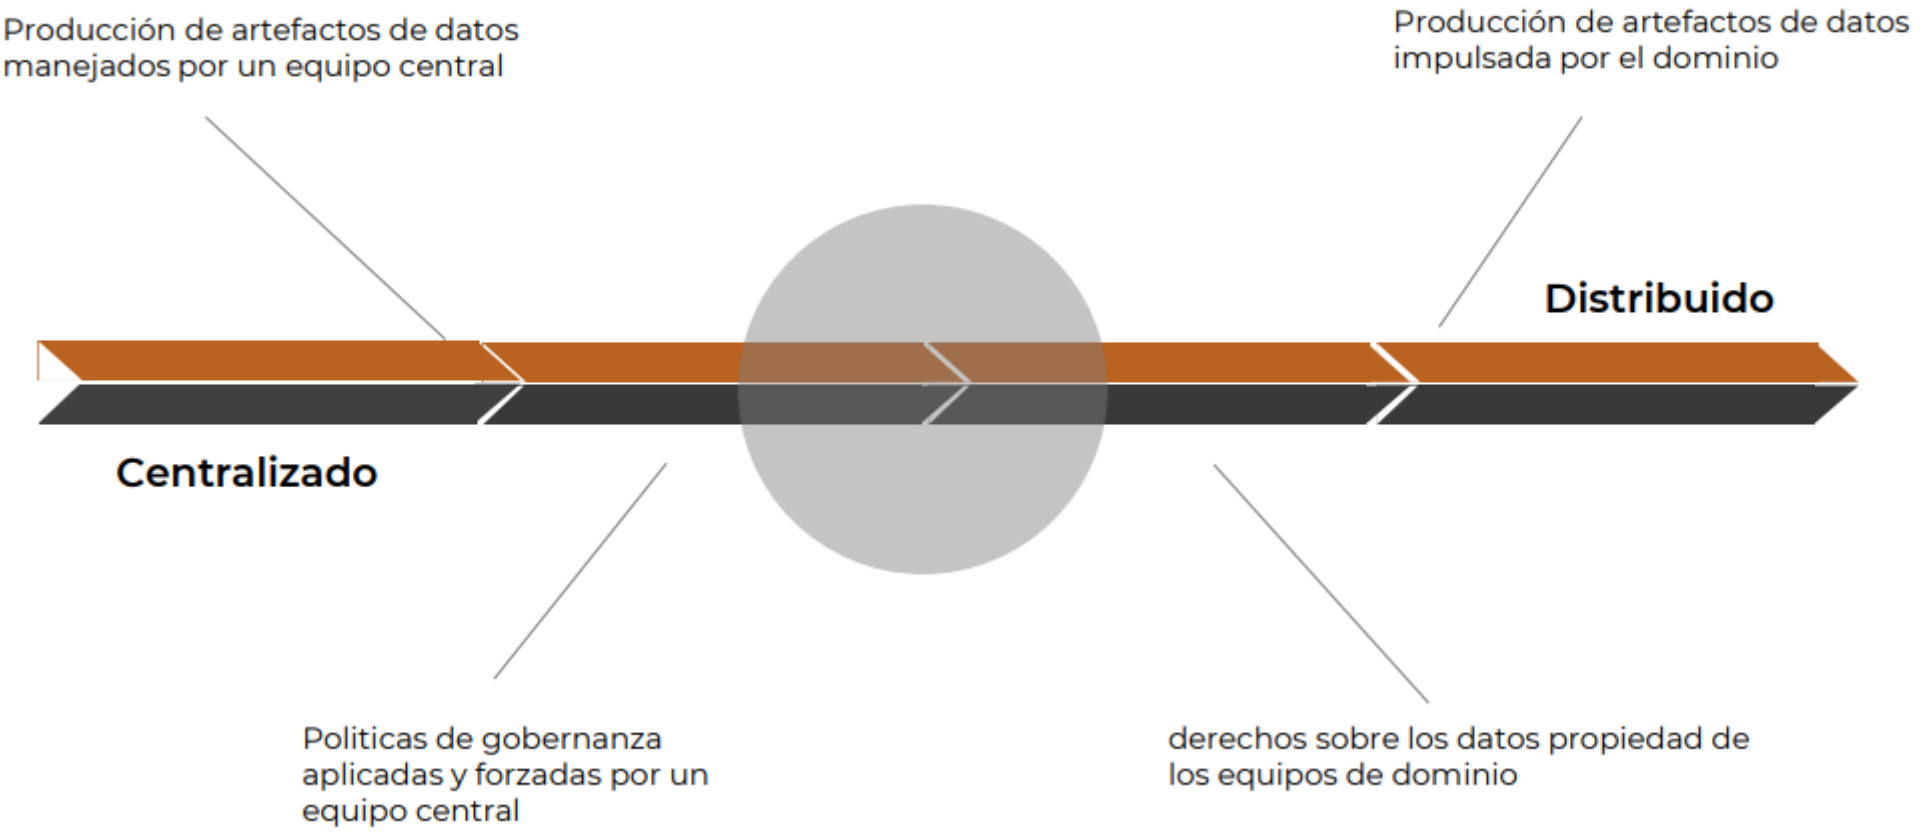

2 Introducción a UC | ¿Qué es Unity Catalog?

Una primera definición de Unity Catalog es que es el ecosistema que propone databricks para que se comuniquen las distintas personas y objetos que pueden generarse en un entonorno de Datos.

2 Introducción a UC | Unity Catalog Claves

Una de las caracteristicas o capacidades mas importantes de UC en Databricks es la posibilidad de **unificar datos** provenientes de diferentes entornos o fuentes.

2 Introducción a UC | Repaso Objetos en UC

Nivel 1 — Catálogo (máximo nivel de organización y gobernanza)Agrupa y aísla los recursos de datos a nivel corporativo. Normalmente refleja unidades organizativas, entornos (dev/test/prod) o dominios globales.

Nivel 2 — Esquema (espacio lógico de trabajo por proyecto o equipo) Subdivisión dentro del catálogo para organizar datos por caso de uso, área funcional o equipo de trabajo, aislando su contexto operativo.

Nivel 3 — Objetos (donde realmente residen o se consumen los datos)
Elementos concretos dentro del esquema:
Tablas → datos estructurados gestionados por UC
Vistas → consultas reutilizables y gobernadas
Volúmenes → archivos crudos o semiestructurados en cloud storage
Funciones → lógica reutilizable para transformar o proteger datos

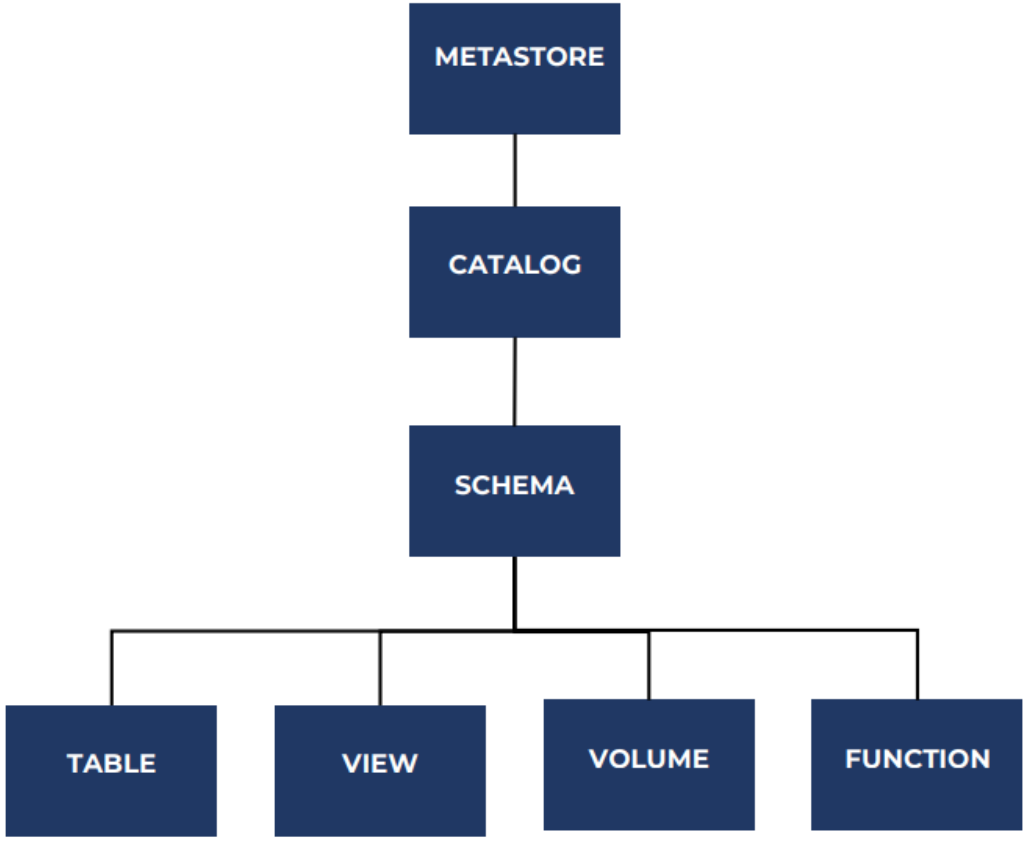

2 Introducción a UC | Intro Control de Accesos

Best Practise!

- Asignar Roles a grupos
- Alinear la asignación de roles con el enfoque de la organización en gobernanza

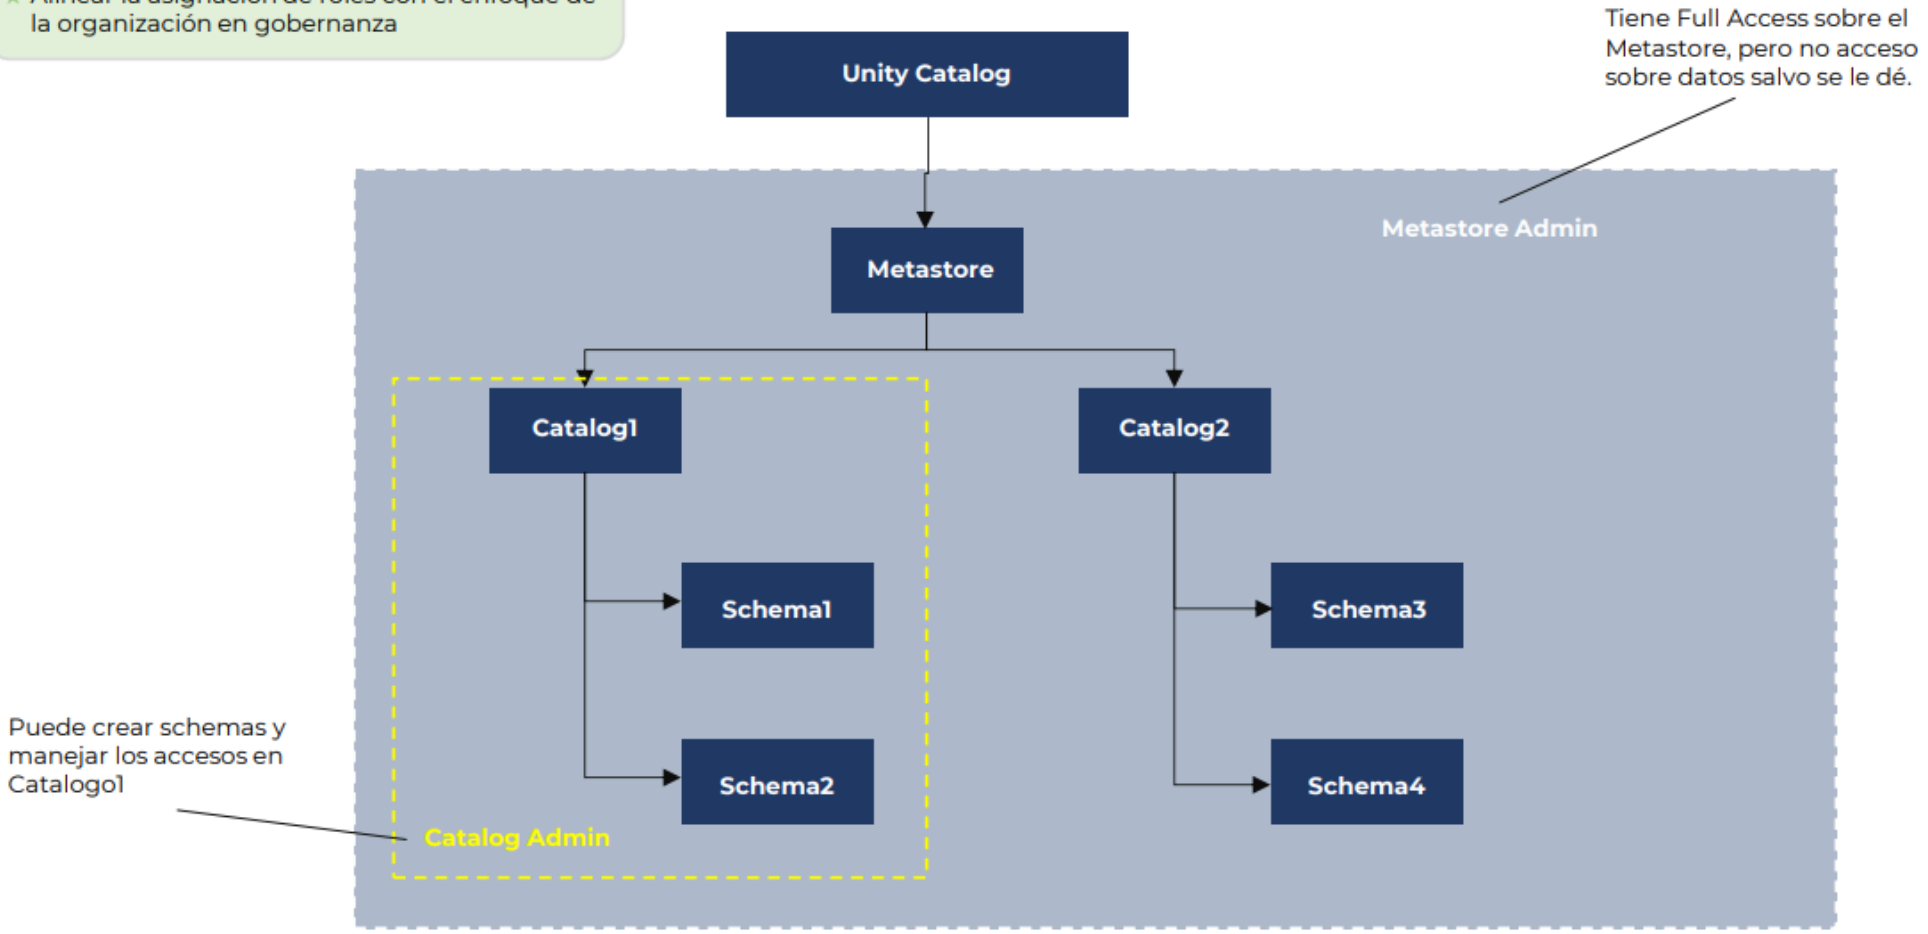

2 Introducción a UC | Unity Catalog desde perspectiva de Gobernanza

Unity Catalog es la solución de **gobernanza unificada de datos e inteligencia artificial** en Databricks.

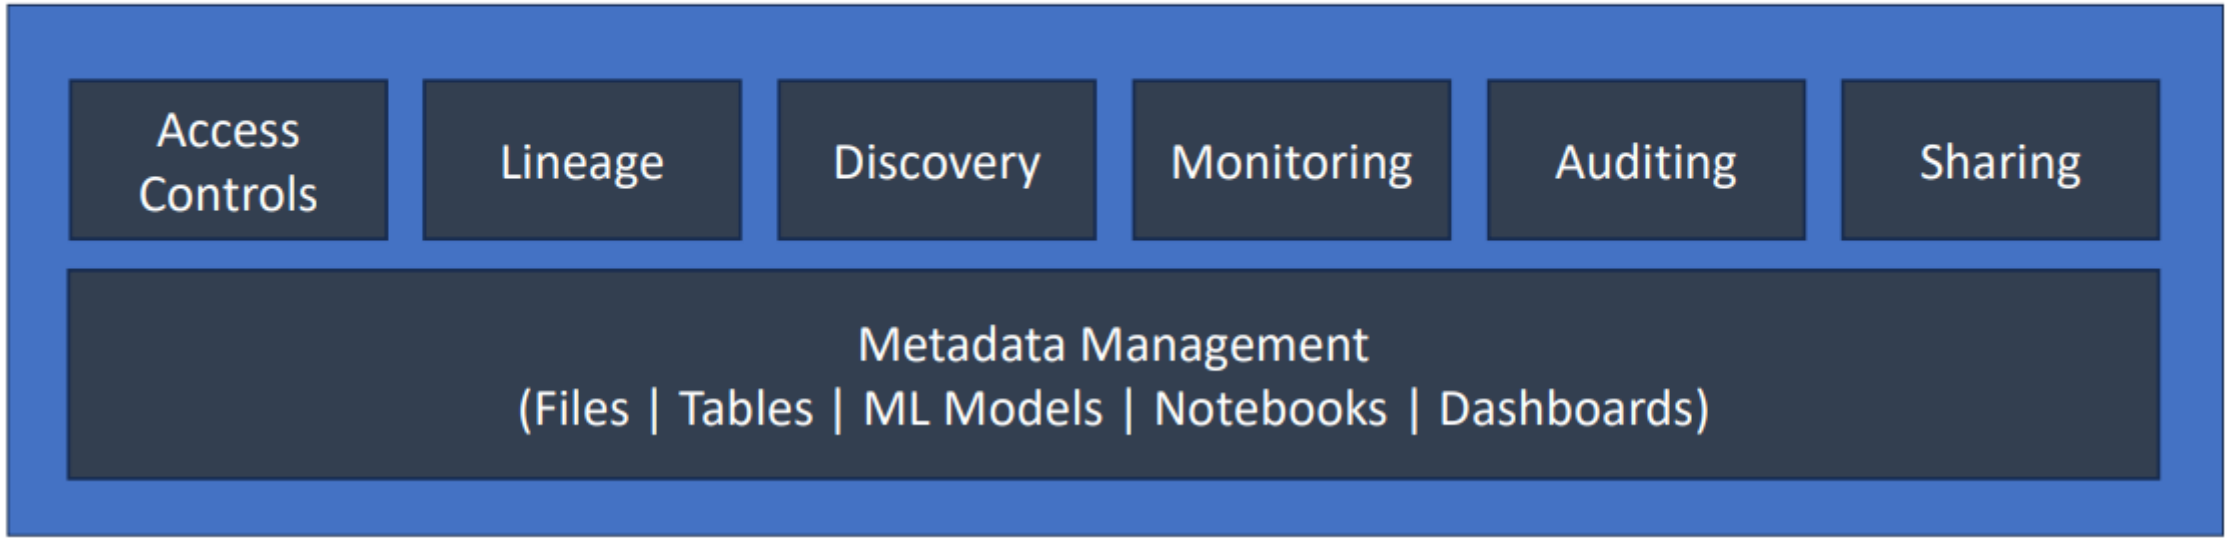

DEMO

CONTROL DE ACCESOS